

PROJECT TITTLE

DAP391m Project

Dự án Trí tuệ Nhân tạo và Khoa học Dữ liệu

FPT University | Ho Chi Minh City

Students: _____ Supervisor/Mentor:

Outline — Nội dung trình bày (10 DS Steps)

Bài báo cáo gồm 4 phần chính, tương ứng 10 bước Data Science:

PART 1 — Problem & Data Understanding (Steps 1-2-3)

Problem Understanding · Data Understanding · Feature Understanding (EDA)

PART 2 — Feature Engineering & Visualization (Steps 3-4)

Feature Engineering · EDA Advanced Charts · Interactive Dashboard (Plotly/Dash)

PART 3 — Modeling, Evaluation & AI Application (Steps 5-6-7-8-9)

Dataset Partition · Data Modelling · Evaluation · Hyper-parameter Tuning · Pipeline · AI App

PART 4 — Conclusion & AI Reflection (Step 10 + Q&A)

Kết luận · AI Audit Log · Human Delta · Hallucination Detection · Self-Assessment

⚠ Lưu ý: Sinh viên trình bày bằng tiếng Anh. Slide hướng dẫn ghi bằng tiếng Việt để dễ đọc.

PART 1

Problem & Data Understanding + SQL

Step 1: Problem Understanding

Step 2: Data Understanding

Step 3: EDA

Research Questions

SQL Queries

Research Questions (Based on Step 1)

Hướng dẫn: Nhóm đặt 3 Research Questions dựa trên Step 1 (Problem Understanding).

Mỗi RQ phải chỉ rõ: Feature? Target? Classification hay Regression?

[RQ1] Example: Which factors most strongly influence [target variable]?

Feature? → Step 3 EDA | Target? → Step 6 Model | Link SQL query GROUP BY

[RQ2] Example: Which ML model predicts [outcome] most accurately?

Step 6: Try many ML methods | Step 7: Compare metrics (Accuracy/RMSE/R2)

[RQ3] Example: How much can [solution] reduce [cost / risk / waste] in practice?

Step 9: Best pipeline → Step 10: Conclusion — số liệu cải thiện cụ thể

⚠ Nhóm thay các ví dụ bằng RQ thực tế của dự án. Phải trích dẫn baseline paper.

Step 1 — Problem Understanding

Key question (EN)	Hướng dẫn thực hiện (VN)
Feature ?	Xác định các biến đầu vào (features): loại dữ liệu số, categorical, text, thời gian
Target ?	Xác định biến mục tiêu (target/label): là gì? Phân phối ra sao? Có mất cân bằng không?
Classification or Regression?	Classification: target rời rạc (0/1, nhãn). Regression: target liên tục (giá, doanh thu)
Business context	Hiểu domain: logistic, fintech, fashion... Tại sao bài toán này quan trọng?
Define success metrics	Định nghĩa thành công: Accuracy/F1 (classification) hay RMSE/R2 (regression)?
RBL: Justify + AI Audit Log	Trích dẫn paper để justify bài toán. Log prompt brainstorm problem statement

Step 2 — Data Understanding

Data issue (EN)	Cách xử lý & Hướng dẫn (VN)
Missing Values ?	Kiểm tra: <code>df.isnull().sum()</code> . Tỷ lệ null, pattern missing. Quyết định drop/fill
Outlier / Noise ?	IQR boxplot, Z-score, scatter plot. Quyết định: giữ, cap, hay loại bỏ
Inconsistent ?	Kiểm tra duplicate, typo, sai định dạng ngày/tháng, đơn vị không nhất quán
Imbalanced ?	<code>value_counts()</code> target. Tỷ lệ class không đều → cần SMOTE / undersampling ở Step 5
Skewness ?	Kiểm tra skewness: <code>df.skew()</code> . Biến lệch phải → log transform ở Step 4
AI Audit Log	Log prompt EDA, data profiling. Mô tả dataset: số dòng × cột, nguồn, định dạng

Step 3 — Feature Understanding (EDA)

EDA type (EN)	Kỹ thuật & Mục đích (VN)
Univariate Analysis	Histogram, KDE, boxplot cho từng biến. Phân phối, range, outlier từng feature
BiVariate Analysis	Scatter plot, bar chart, heatmap 2 biến. Tương quan với target, phát hiện pattern
MultiVariate Analysis	Pairplot, correlation matrix, heatmap đầy đủ. Mối quan hệ nhiều biến cùng lúc
Geospatial (if applicable)	Choropleth map, Folium interactive map nếu dữ liệu có latitude/longitude
Insight documentation	Mỗi biểu đồ: title, axis labels, insight 1-2 câu tiếng Anh — liên kết với RQ
RBL + AI Audit Log	Chọn loại biểu đồ có lý do (RBL). Log prompt tạo chart, evidence-based insights

PART 2

Feature Engineering & Visualization

Step 4: Feature Engineering

EDA Advanced Charts

Interactive Dashboard (Plotly/Dash)

Step 4 — Feature Engineering

Technique (EN)	Hướng dẫn chi tiết (VN)
Skewness / Missing / Outlier Handling	Log transform (skew), fillna/dropna (missing), cap/remove (outlier) — ghi lý do từng bước
Feature Enrichment	Tạo biến mới từ business domain: ratio, difference, aggregation theo nhóm, time lag
Feature Transformation	Polynomial features, binning (pd.cut), log/sqrt transform cho phân phối lệch
Feature Selection	Correlation filter ($ r > 0.9$ drop), VIF (multicollinearity), SelectKBest, RFE
Feature Encoding	LabelEncoder (ordinal), OneHotEncoder (nominal), TargetEncoder (high cardinality)
Feature Scaling	Normalization: MinMaxScaler [0,1]. Standardization: StandardScaler (z-score). Khi nào dùng?

Data Visualization in Advanced (Step 3 cont.)

Chart type (EN)	Khi nào dùng & Yêu cầu (VN)
Heatmap (correlation / density)	Tương quan biến / mật độ không gian. Cần color scale, nhãn trục, annotation giá trị
Area / Line chart	Xu hướng theo thời gian. Highlight đỉnh/đáy, ghi chú sự kiện, nhiều series cùng lúc
Waffle / Treemap / Pie	Tỷ lệ phân bố — dùng label %, tránh khi quá nhiều thành phần (hơn 7 nhóm)
Scatter / Pairplot	Tương quan 2 biến, phát hiện cụm. Cần hue theo nhóm, regression line, r-value
Word Cloud / Choropleth Map	Văn bản: Word Cloud. Không gian: Choropleth / Folium interactive map với color encoding
RBL + AI Audit Log	Mỗi chart: title, axis labels, insight 1-2 câu bằng EN. Chọn loại chart có lý do (RBL)

Interactive Dashboard (Plotly & Dash)

Requirement (EN)	Hướng dẫn chi tiết (VN)
Dashboard framework	Plotly Dash (ưu tiên), Power BI, Tableau, Looker Studio, hoặc RStudio Shiny
Min. 3 interactive charts	3 biểu đồ khác nhau, mỗi biểu đồ liên kết một RQ cụ thể
Filter / Dropdown	Người dùng lọc được theo thời gian, danh mục, khu vực — demo trực tiếp
KPI summary cards	Hiển thị chỉ số tổng hợp: total, rate, growth % — dễ đọc ngay khi mở
Geospatial chart	Nếu có dữ liệu vị trí: thêm Choropleth map hoặc Folium interactive map
RBL + AI Audit Log	Giải thích tại sao chọn công cụ này (RBL). Log prompt thiết kế dashboard

PART 3

Modeling, Evaluation & AI Application

Step 5: Dataset Partition

Step 6: Modelling

Step 7: Evaluation

Step 8: Tuning

Step 9: Pipeline + App

Step 5 — Dataset Partition & Step 6 — Data Modelling

STEP 5 Dataset Partition

- *Imbalanced Handling: SMOTE, undersampling, class_weight nếu target mất cân bằng*
- Train / Test Split: `train_test_split(X, y, test_size=0.2, stratify=y)`
- *Stratified split khi classification — đảm bảo tỷ lệ class trong cả train và test*
- Cross-Validation: K-Fold CV để đánh giá ổn định — tránh overfitting trên 1 split

STEP 6 Data Modelling

- *Try many ML methods: không chỉ dùng 1 mô hình — so sánh ít nhất 5 approaches*
- For Regression: Linear, Ridge, Lasso, Random Forest, XGBoost, LightGBM
- For Classification: LogReg, SVM, RF, XGBoost, LightGBM, LSTM (sequence)
- *Pipeline sklearn: `Pipeline([['scaler', ss], ('model', rf)])` — tránh data leakage*

Step 7 — Data Evaluation

Metric (EN)	Ý nghĩa & Khi nào dùng (VN)
Accuracy	Tỷ lệ đúng tổng thể. Dùng khi các class cân bằng. Không dùng khi imbalanced
Precision / Recall / F1-score	Precision: đúng trong positive dự đoán. Recall: bắt được positive thực. F1: harmonic mean
AUC-ROC	Diện tích dưới ROC curve. AUC=1 hoàn hảo, AUC=0.5 random. Tốt cho imbalanced
R2 Score	Regression: tỷ lệ variance giải thích được. R2=1 hoàn hảo, R2<0 tệ hơn mean
MSE / RMSE / MAE	MSE: mean squared error. RMSE: căn bậc 2 MSE (đơn vị gốc). MAE: ít nhạy outlier hơn
Compare with baseline paper	So sánh metrics của nhóm với kết quả trong paper của dự án. Giải thích sự khác biệt

Step 8 — Hyper-parameter Tuning & Step 9 — Build Pipeline

STEP 8 Hyper-parameter Tuning

- *Cross Validation (CV): K-Fold để estimate generalization error*
- GridSearchCV: exhaustive search all param combinations
- RandomizedSearchCV: faster for large param space
- *Regularization: L1 (Lasso) → feature selection. L2 (Ridge) → shrink weights*
- Penalty: alpha/C/lambda — tune to reduce overfitting

STEP 9 Build Best Pipeline

- *Chọn best model + best hyperparameters từ Step 7-8*
- sklearn Pipeline: preprocessor + best_model end-to-end
- *Tránh data leakage: fit scaler chỉ trên train, transform cả train+test*
- Save model: `joblib.dump(pipeline, 'best_model.pkl')`
- *Integrate pipeline vào ứng dụng AI: predict từ input mới*

Integrating AI Services & Develop Application

What to build (EN)	Hướng dẫn chi tiết (VN)
AI service integration	AWS Lex+Transcribe / Watson IBM / GCP — chatbot hoặc voice Q&A về kết quả dự án
Application architecture	Sơ đồ: data → pipeline (Step 9) → dashboard + AI service + UI
Core features	Upload data, chạy pipeline, hiển thị prediction, đưa khuyến nghị từ model
Dashboard integration	Plotly/Dash tích hợp vào app — filter, KPI cards, chart liên kết RQ
Live demo required	Demo end-to-end trong buổi báo cáo — chuẩn bị screenshot dự phòng
RBL + AI Audit Log	Justify chọn service và công nghệ (RBL). Log prompt phát triển app; Human Delta

PART 4

Conclusion & AI Reflection (Step 10 + Q&A)

Step 10: Conclusion

AI Audit Log (15-20 Prompts)

Human Delta

Hallucination (≥ 3)

Self-Assessment

Step 10 — Conclusion + Q&A + AI Reflection (20 points)

Step 10: Conclusion	AI Audit Log	Human Delta
• Answer each RQ with evidence from results • Best model: name, metrics, vs baseline paper • Practical implications for the domain • Limitations & Future Work • <i>Kết luận bằng số liệu cụ thể, không chỉ mô tả</i>	• 15-20 Core Prompts logged (4 sheets xlsx) • Evaluate each AI output: correct / wrong • Detect ≥ 3 hallucinations with evidence • Self-Assessment Checklist completed • <i>Dùng AI Audit Log Template.xlsx — nộp kèm báo cáo</i>	• What your team did WITHOUT AI • Domain knowledge decisions independently • How you corrected AI errors • Critical thinking & creative synthesis • <i>Chứng minh tư duy phản biện — bắt buộc</i>

Q&A session: Giảng viên hỏi về kết quả, lý do chọn method, AI Audit Log, Human Delta. Mỗi thành viên phải trả lời được ít nhất 1 câu.

Q&A Preparation & Time Management

Chuẩn bị Q&A — lưu ý quan trọng:

- Every member must understand ALL 10 steps, not only their own section
- Be ready to explain: 'Why this model?' 'Why this chart?' 'What does the metric mean?'
- AI Audit Log must be present and ready to show when asked by the examiner
- If AI was wrong (Step 7 metrics, Step 4 technique), explain how your team fixed it
- Connect ALL findings back to the 3 Research Questions from Step 1

Thời gian trình bày tối đa:

- Part 1 (Steps 1-2-3 + SQL): 8-10 minutes
- Part 2 (Steps 3-4 Viz + Dashboard): 5-7 minutes
- Part 3 (Steps 5-6-7-8-9 + App): 8-10 minutes
- Part 4 (Step 10 + Q&A + AI Reflection): 5-7 minutes

TOTAL <= 35 minutes

Rubrics Overview — DAP391m Final Project

#	Evaluation Criteria	Max Points	Hướng dẫn AI Audit (VN)
1	Final Report (LaTeX + Slides)	20 pts	Log prompt viết báo cáo, format LaTeX Springer; reflection độ chính xác
2	Business Understanding + Data Prep	5 pts	Log prompt brainstorm, tìm data, câu hỏi nghiên cứu, data collection
3	Data Analysis with Python	10 pts	Log prompt code Python, feature engineering, justify lựa chọn
4	Data Visualization in Advanced	10 pts	Log prompt tạo chart, dashboard; evidence-based insights
5	Build Model for Prediction	15 pts	Log prompt huấn luyện, so sánh ≥ 5 mô hình với baseline paper
6	Integrating AI Services	10 pts	Log prompt tích hợp API/AI services; justify lựa chọn
7	Develop AI-Powered Application	10 pts	Log prompt phát triển app; Human Delta; architecture diagram
8	Q&A + AI Reflection	20 pts	AI Audit Log đầy đủ; Human Delta; Hallucination ≥ 3 ; Checklist

Step 6-7 — Model Comparison Template

Model	RMSE / Accuracy	MAE / F1-score	R2 / AUC	vs Baseline
Linear Regression	[fill]	[fill]	[fill]	[fill]
Ridge / Lasso	[fill]	[fill]	[fill]	[fill]
Random Forest	[fill]	[fill]	[fill]	[fill]
XGBoost	[fill]	[fill]	[fill]	[fill]
LightGBM / LSTM	[fill]	[fill]	[fill]	[fill]
Baseline (paper)	[cite paper]	[cite]	[cite]	reference

⚠ Highlight hàng tốt nhất màu xanh. Giải thích tại sao mô hình đó tốt hơn baseline. RMSE/MAE: thấp tốt; R2/Accuracy/AUC: cao tốt.

Checklist — Before the Presentation

Checklist item	Status
Step 1-2: Problem & Data Understanding documented (Feature/Target/Metrics)	☐ Done
Step 3-4: EDA charts + Feature Engineering notebook — re-runnable	☐ Done
SQL queries: group size x 3 (min 5) — each links to an RQ (không bắt buộc)	☐ Done
Step 5: Imbalanced handling + proper train/test split (stratified)	☐ Done
Step 6: Compared ≥ 5 ML models on same train/test split	☐ Done
Step 7: Metrics table with baseline paper comparison	☐ Done
Step 8: GridSearchCV / CV tuning applied to best model	☐ Done
Step 9: sklearn Pipeline saved (no data leakage)	☐ Done
AI service integrated + dashboard demo-able live	☐ Done
Step 10: Conclusion answers all 3 RQs with evidence	☐ Done
AI Audit Log: 15-20 prompts, ≥ 3 hallucinations, Human Delta	☐ Done
Total presentation time ≤ 35 minutes (rehearsed)	☐ Done